

# Задача №11: Анализ систем и аппроксимация матриц через SVD

## 1 Теоретическая часть

**Теория.** Для любой матрицы  $A \in \mathbb{R}^{m \times n}$  существует разложение (сингулярные числа определены единственным образом):

$$A = U \Sigma V^T,$$

где:

- $U \in \mathbb{R}^{m \times m}$ , ортогональная матрица:  $U^T U = I_m$ . Столбцы  $U = (u_1, \dots, u_m)$  — левые сингулярные векторы.
- $V \in \mathbb{R}^{n \times n}$ , ортогональная матрица:  $V^T V = I_n$ . Столбцы  $V = (v_1, \dots, v_n)$  — правые сингулярные векторы.

- $\Sigma \in \mathbb{R}^{m \times n}$ , «диагональная» матрица вида  $\Sigma = \begin{pmatrix} \sigma_1 & & 0 \\ & \ddots & \\ 0 & \dots & \sigma_k \\ & & 0 \end{pmatrix}$ , где  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_k > 0$  — сингулярные числа. Также обозначают  $\Sigma_n = \text{diag}(\sigma_1, \dots, \sigma_n)$ .

**Геометрическое пояснение.** Отображение  $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$  переводит единичную сферу в пространстве  $\mathbb{R}^n$  в эллипсоид в пространстве  $\mathbb{R}^m$ . Полуоси этого эллипсоида направлены вдоль левых сингулярных векторов  $u_1, u_2, \dots, u_m$ , а их длины равны соответствующим сингулярным числам  $\sigma_1, \sigma_2, \dots, \sigma_n$ . Остальные направления дополняются до ортогонального базиса.

**Алгебраическое пояснение.** Для любого вектора  $x \in \mathbb{R}^n$  его можно разложить по базису из правых сингулярных векторов:

$$x = \sum_{i=1}^n c_i v_i \quad (\text{так как } V \text{ — базис}).$$

Тогда действие матрицы  $A$  на вектор  $x$  можно записать как:

$$Ax = U \Sigma V^T x = (u_1, \dots, u_m) \Sigma V^T \left( \sum_{i=1}^n c_i v_i \right).$$

Поскольку  $V^T V = I_n$ , имеем  $V^T (\sum c_i v_i) = (c_1, \dots, c_n)^T$ . Следовательно:

$$Ax = \sum_{i=1}^n c_i \sigma_i u_i.$$

**Теорема 1** (О решении задачи наименьших квадратов, ранг полный). Рассмотрим переопределенную систему  $Ax = b$  (задача наименьших квадратов — ЗНК). Пусть  $\text{rank}(A) = n$  (полный столбцовый ранг). Тогда нормальное псевдорешение имеет вид:

$$x = V\Sigma^{-1}U^Tb.$$

*Доказательство.* Задача наименьших квадратов сводится к решению нормального уравнения:

$$A^T Ax = A^T b \implies x = (A^T A)^{-1} A^T b.$$

Подставим SVD-разложение  $A = U\Sigma V^T$ :

$$\begin{aligned} x &= (V\Sigma U^T U\Sigma V^T)^{-1} V\Sigma U^T b = \\ &= (V\Sigma^2 V^T)^{-1} V\Sigma U^T b = \\ &= V\Sigma^{-2} V^T V\Sigma U^T b = \\ &= V\Sigma^{-1} U^T b. \end{aligned}$$

□

**Теорема 2** (О решении ЗНК, ранг неполный). Пусть  $\text{rank}(A) = k < n$ . Тогда сингулярное разложение имеет блочный вид:

$$A = U \begin{pmatrix} \Sigma_k & 0 \\ 0 & 0 \end{pmatrix} V^T.$$

Тогда множество решений ЗНК имеет вид:  $x = V_1 \Sigma_k^{-1} U_1^T b + V_2 z$ , где  $z \in \mathbb{R}^{n-k}$  — произвольный вектор.

*Доказательство.* Минимизируем невязку:

$$\|b - Ax\|_2 \rightarrow \inf_x \iff \|b - U\Sigma V^T x\|_2 \rightarrow \inf_x.$$

Умножим выражение под нормой на ортогональную матрицу  $U^T$  (умножение на ортогональную матрицу сохраняет евклидову норму,  $\|U^T y\|_2 = \|y\|_2$ ):

$$\|U^T b - \Sigma V^T x\|_2 \rightarrow \inf_x.$$

Разобьем матрицы  $U$  и  $V$  на блоки, соответствующие ненулевым сингулярным числам:

$U = (U_1, U_2)$  и  $V = (V_1, V_2)$ . Тогда  $U^T b = \begin{pmatrix} U_1^T b \\ U_2^T b \end{pmatrix}$ . Получаем:

$$\left\| \begin{pmatrix} U_1^T b \\ U_2^T b \end{pmatrix} - \begin{pmatrix} \Sigma_k V_1^T x \\ 0 \end{pmatrix} \right\|_2 \rightarrow \inf_x \iff \left\| \begin{pmatrix} U_1^T b - \Sigma_k V_1^T x \\ U_2^T b \end{pmatrix} \right\|_2 \rightarrow \inf_x.$$

Нижний блок  $U_2^T b$  не зависит от  $x$ . Минимум достигается, когда верхний блок равен нулю. Обозначим  $V^T x = \begin{pmatrix} V_1^T x \\ V_2^T x \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$ . Решение для первой компоненты:

$$y_1 = \Sigma_k^{-1} U_1^T b.$$

Тогда искомый вектор  $x$  восстанавливается как  $x = Vy = (V_1, V_2) \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$ :

$$x = V_1 y_1 + V_2 y_2 = V_1 \Sigma_k^{-1} U_1^T b + V_2 y_2, \quad \forall y_2 \in \mathbb{R}^{n-k}.$$

□

**Замечание.** Если нас интересует вектор минимальной длины (нормальное псевдорешение), то  $x_{\min} = V_1 \Sigma_k^{-1} U_1^T b$ , то есть  $y_2 = 0$ .

*Доказательство.* Поскольку столбцы матрицы  $V$  ортонормальны, имеем ортогональное разложение:

$$x = \sum_{i=1}^k c_i v_i + \sum_{j=k+1}^n \beta_j v_j, \quad \text{где } \beta_j \text{ — компоненты } y_2.$$

Длина вектора  $\|x\|_2^2 = \sum c_i^2 + \sum \beta_j^2$ . Мы хотим минимизировать длину. Так как коэффициенты  $c_i$  (или  $y_1$ ) жестко фиксированы для обеспечения минимума невязки, а  $\beta_j$  на минимизацию невязки не влияют, то для минимизации длины самого вектора  $x$  необходимо положить  $\beta_j = 0$ , то есть  $y_2 = 0$ .  $\square$

**Теорема 3** (Теорема Эккарта — Янга — Мирского). Пусть  $A \in \text{Mat}_{m \times n}(\mathbb{R})$  и  $\text{rank}(A) = n$ . Тогда наилучшая аппроксимация матрицы  $A$  матрицей меньшего ранга  $k$  в норме  $\|\cdot\|_2$ :

$$\inf_{\substack{B \in \text{Mat}_{m \times n}(\mathbb{R}) \\ \text{rank}(B) \leq k}} \|A - B\|_2$$

достигается (и притом единственно) на матрице усеченного SVD-разложения:

$$A_k = U \begin{pmatrix} \Sigma_k & 0 \\ 0 & 0 \end{pmatrix} V^T.$$

*Доказательство.*

1. Очевидно, что  $A_k$  имеет ранг  $k$ . Рассмотрим разность:

$$A - A_k = U \begin{pmatrix} 0 & 0 \\ 0 & \Sigma_{n-k} \end{pmatrix} V^T.$$

Покажем, что  $\|A - A_k\|_2 = \sigma_{k+1}$  (где  $\sigma_{k+1}$  — максимальное сингулярное число в блоке  $\Sigma_{n-k}$ , так как на диагонали стоят обнуленные  $\sigma_1 \dots \sigma_k$ ).

Действительно, норма матрицы равна максимальному сингулярному числу, поэтому  $\|A - A_k\|_2 \leq \sigma_{k+1}$ . С другой стороны:

$$\|A - A_k\|_2 \geq \frac{\|(A - A_k)v_{k+1}\|_2}{\|v_{k+1}\|_2} = \|\sigma_{k+1}u_{k+1}\|_2 = \sigma_{k+1}.$$

Следовательно,  $\|A - A_k\|_2 = \sigma_{k+1}$ .

2. Пусть теперь  $B$  — любая матрица такая, что  $\text{rank}(B) = k$ . Рассмотрим ядро матрицы  $B$ , то есть подпространство  $\ker B$ . По теореме о ранге и дефекте,  $\dim(\ker B) = n - k$ . Рассмотрим также подпространство  $\text{span}\langle v_1, \dots, v_{k+1} \rangle$ , его размерность равна  $k + 1$ . Поскольку сумма их размерностей  $(n - k) + (k + 1) = n + 1 > n$ , эти два подпространства пересекаются нетривиально:

$$\exists \xi \in \ker B \cap \text{span}\langle v_1, \dots, v_{k+1} \rangle, \quad \xi \neq 0.$$

Не умаляя общности, нормируем этот вектор:  $\|\xi\|_2 = 1$ . Разложим его по базису:  $\xi = \sum_{i=1}^{k+1} \alpha_i v_i$ , причем  $\sum \alpha_i^2 = 1$ . Так как  $\xi \in \ker B$ , то  $B\xi = 0$ .

Тогда оценим норму разности операторов на этом векторе  $\xi$ :

$$(A - B)\xi = A\xi - 0 = A \left( \sum_{i=1}^{k+1} \alpha_i v_i \right) = \sum_{i=1}^{k+1} \alpha_i \sigma_i u_i.$$

Норма матрицы не меньше нормы ее действия на единичный вектор:

$$\|A - B\|_2 \geq \|(A - B)\xi\|_2 = \left\| \sum_{i=1}^{k+1} \alpha_i \sigma_i u_i \right\|_2 = \sqrt{\sum_{i=1}^{k+1} (\alpha_i \sigma_i)^2}.$$

Поскольку сингулярные числа упорядочены по убыванию,  $\sigma_i \geq \sigma_{k+1}$  для всех  $i \leq k+1$ :

$$\|A - B\|_2 \geq \sqrt{\sum_{i=1}^{k+1} \alpha_i^2 \sigma_{k+1}^2} = \sigma_{k+1} \sqrt{\sum_{i=1}^{k+1} \alpha_i^2} = \sigma_{k+1} \cdot 1 = \sigma_{k+1}.$$

Таким образом, для любой матрицы  $B$  ранга  $k$  ошибка аппроксимации  $\|A - B\|_2 \geq \sigma_{k+1}$ . Минимум достигается на  $A_k$ .

□

## 2 Численные эксперименты

В рамках работы была реализована программа на языке Python (с использованием библиотек `numpy` и `scipy.linalg.svd`), тестирующая метод сингулярного разложения на трех типах матриц.

### 2.1 Случай 1: Плохо обусловленная верхнетреугольная матрица

Рассматривается матрица  $A \in \mathbb{R}^{100 \times 100}$  с единицами на диагонали и  $(-1)$  выше неё.

- **Проблема:** Матрица формально невырожденная, но спектр сингулярных чисел  $\sigma_i$  убывает крайне быстро (от  $\approx 5.6$  до  $\approx 10^{-3}$ ).
- **Результат:** В точной арифметике система  $Ax = b$  разрешима. Однако на практике число обусловленности  $\kappa(A) = \sigma_1/\sigma_n$  велико. Использование усеченного SVD (с отсечением сингулярных чисел меньше заданного  $\varepsilon = 10^{-12}$ ) позволяет стабильно найти нормальное псевдорешение.

### 2.2 Случай 2: Вырожденная трехдиагональная матрица

Рассматривается матрица  $A$  со значениями  $(2, -1, -1)$  на диагоналях и модифицированными граничными условиями (значения  $-2$  в углах).

- **Особенность:** Матрица вырождена,  $\text{rank}(A) = 99 < 100$ . В процессе вычислений одно из сингулярных чисел определяется как машинный ноль ( $\approx 10^{-16}$ ). Стандартный метод Гаусса (или `np.linalg.solve`) к такой системе неприменим.
- **Метод решения:** Метод SVD позволил выделить вектор  $v_n$  из матрицы  $V$  (соответствующий  $\sigma_n \approx 0$ ), который задает базис одномерного ядра матрицы  $A$ . Общее решение восстанавливается в виде  $x = x_{\min} + C \cdot v_n$ . Расчеты показали, что ошибка восстановления точного вектора таким образом близка к машинному нулю.

## 2.3 Случай 3: Низкоранговая аппроксимация (Синус-матрица)

Рассматривается матрица размерности  $5 \times 5$ , элементы которой заданы как  $A_{i,j} = \sin(\pi x_i) \sin(\pi y_j)$ , где  $x_i, y_j$  — узлы равномерной сетки.

- **Анализ:** Поскольку переменные  $x$  и  $y$  сепарабельны (каждый элемент есть произведение функции от  $i$  на функцию от  $j$ ), строки матрицы линейно зависимы. Теоретический ранг такой матрицы равен 1.
- **Результат:** Анализ спектра сингулярных значений подтверждает теорию: только  $\sigma_1$  отлично от нуля (с точностью до ошибок округления), что позволяет сжимать подобные данные без потерь, оставляя только первую компоненту усеченного SVD.